



¿Podemos predecir si una estación de Bicing se quedará sin bicicletas en los próximos 60 minutos?

*Proyecto final del Curso de Machine Learning y Redes Neuronales
Por Hamed Fallah*

Los datos

≈ 24.4M

observaciones
(estado de las estaciones, no viajes)

≈ 450

estaciones por día al inicio



Agosto 2018 – Marzo 2019




Snapshots del estado de cada estación
cada pocos minutos



Variables clave: bicicletas, plazas libres,
estado, latitud, longitud



Problemas de cobertura



Septiembre–octubre 2018

Hay un gap claro en los datos durante estas semanas.



Marzo 2019

La cobertura de estaciones cae mucho y la tasa de casos positivos baja a ~1.8%. Por eso se excluye de la evaluación principal.

Objetivo y variables

Target = 1

La estación se queda sin bicicletas en los próximos 60 min (y sigue abierta)



Estado actual

bicis disponibles, ratio de ocupación



Tiempo

hora, día de la semana, fin de semana, mes

Target = 0

La estación sigue teniendo bicicletas disponibles en los próximos 60 min



Historial reciente

bicis hace 15/30 min, cambios recientes



Ubicación

latitud, longitud

División temporal

Entrenar → Ajustar → Evaluar

TRAIN	VAL.	TEST	MAR
Ago – Dic 2018 9,52 M obs. 9,00% positivos	Ene 2019 2,97 M obs. 9,11% positivos	Feb 2019 1,71 M obs. 7,42% positivos	excluido

Marzo se deja fuera de la evaluación principal por la caída de cobertura de estaciones.

Class Imbalance:


Clase negativa: 91.46%

Clase positiva: 8.54%

Comparación de modelos

Resultados sobre el set de validación (enero 2019)

	Model	Accuracy	Precision	Recall
0	Dummy Classifier	0.908863	0.000000	0.000000
1	Rule-Based Baseline	0.891650	0.433186	0.612233
2	Logistic Regression	0.916826	0.613054	0.236899
3	Decision Tree	0.931672	0.674959	0.482750
4	Random Forest	0.932240	0.696076	0.455301
5	Neural Network	0.926509	0.683902	0.360022



Elegido: Decision Tree — mejor equilibrio precisión / recall para detectar estaciones con riesgo de quedarse vacías

Resultado final

Decision Tree · evaluado en datos de febrero 2019 (fuera del entrenamiento)

94.05%

Accuracy

63.66%

Precision

46.23%


Recall

Final Decision Tree Confusion Matrix - Test Set

True label	Predicted label	
	Not empty	Empty
Not empty -	True Negative 1,551,261	False Positive 33,502
Empty -	False Negative 68,282	True Positive 58,700

El modelo detecta menos de la mitad de los casos reales de estación vacía (recall 46%), pero cuando predice "vacía" acierta en torno al 64% de las veces (precision).

Mapa de predicciones



● Estación seleccionada

Bicis ahora: 1

Predicción: vacía en 60 min

Target real: 1

Rojo = predicción de estación vacía en 60 min

Azul = predicción de estación no vacía

Limitaciones y conclusión

- Cobertura de estaciones decreciente a lo largo del periodo
- Gap de datos en septiembre–octubre 2018
- Datos de snapshot, no de viajes individuales
- Sin variables de clima ni eventos especiales

“

La historia reciente de una estación puede ayudar a predecir el riesgo de quedarse vacía a corto plazo, pero la calidad y la cobertura de los datos afectan mucho a la evaluación del modelo.